

데이터 수집 개요서 (Data Collection Overview)

프로젝트명: AI 기반 웹소설 글로벌 현지화 동시 연재 어시스턴트 – 라이터(w.LiGHTER)

팀명: 이세계출판부 (SKN24-5Team)

팀원: 고아라, 김유진, 권민제, 이동민, 진세형, 최현진

문서 버전: v4.0

작성일: 2026-05-26

기준 문서: 요구사항 정의서

목차

1. 수집 목적
2. 요구사항-데이터 매핑
3. 데이터 수집
4. 데이터 수집 파이프라인

1. 수집 목적

본 문서는 AI 기반 웹소설 글로벌 현지화 동시 연재 어시스턴트인 라이터(w.Lighter) 구현을 위해 필요한 데이터 수집 체계를 정의하는 데 목적이 있다. 본 문서는 서비스 요구사항을 충족하기 위한 데이터의 출처, 수집 방법, 수집 절차를 정리하고, 수집 과정의 법적·윤리적 적합성을 확보하는 것을 목표로 한다.

1차 MVP단계에서는 현대 한국 사회·문화 요소가 반영된 작품을 우선 대상으로 하여, 국가별 문화 맥락이 반영된 현지화 가이드 데이터 확보에 집중한다. 이때 수집 대상은 플랫폼 가이드라인, 규제 문서, 문화 코드 자료, 현지화 표현 사전 및 관련 코퍼스로 한정한다.

2. 요구사항 - 데이터 매핑

기능	요구사항	필요한 데이터
번역 실행	REQ-CHAP-006	① 고유명사/문화의존 명사 매핑 ② 문화 오해 유발 표현 감지 기준 ③ 민감표현 판별 기준 ④ 국가별 권장 분량 기준
현지화 사전 가이드	REQ-GDE-001	국가별 독자층 특성 + 문화유의사항 + 플랫폼 규정

3. 데이터 수집

국가 코드는 국제표준화기구(ISO)의 ISO 3166-1 alpha-2 표준 코드 체계에 따라 US, CN, JP, TH의 2자리 코드로 관리한다. 원문 한국어 처리나 비교 기준이 필요한 경우에는 별도 언어 자원으로 구분하여 관리한다.

3-1. 콘텐츠 가이드라인 및 규제

US는 Wattpad, Tapas, WebNovel의 플랫폼 가이드라인과 정책 문서를 우선 수집 대상으로 삼는다. 이 자료는 번역 결과의 민감 표현 판별 기준, 국가별 권장 분량 기준, 현지화 가이드의 플랫폼 규정 항목을 도출하는 데 활용한다.

JP는 小説家になろう, カクヨム, アルファポリスの 공식 가이드라인을 수집한다. 이 자료는 작품 게시 FAQ, 표현 제한, 독자 기대치와 같은 플랫폼 운영 기준을 확인하는 데 활용한다.

CN은 起点中文网, 番茄小说, 晋江文学城的 가이드라인과 함께 국가신문출판국의 관련 규정을 수집한다.

TH는 Computer Crime Act(2017) 및 관련 규정, ReadAWrite, Dek-D, Joylada의 게시 규칙을 수집한다. 이 자료는 태국 현지화 가이드의 법적 제약과 플랫폼 규정 항목을 구성하는 데 활용한다.

- 데이터 예시

수집 데이터 요약	HTML, PDF (총 17건)
수집 데이터 예시	ガイドライン はじめに ガイドラインに関して このガイドラインには、利用規約への違反またはそれに準じるものとして運営対応の対象となる可能性がある事例や基準等を記載しています。 ただし、このガイドラインはあくまで目安であり、警告が行われるかどうかや、さらにその先の処罰が行われるか等の判断はケースごとに異なります。 また、社会・環境の変化によっても随時変更される可能性がございますこと、あらかじめご了承ください。 なお、このガイドラインは原則として小説家になろうグループでのみ適用されるものとしております。 小説家になろうへ掲載が可能な内容について 現在の小説家になろうグループサイトでは、利用規約にて定義しております「作品」に該当するもののみ本サイト上での作品掲載として許可しております。 利用規約、各種ガイドラインに違反する場合のみでなく、利用規約上の「作品」に該当しないテキスト等が作品として掲載されていた場合にも、運営対応の対象となる可能性がございますのでご注意ください。 출처: 小説家になろう

수집 방법	크롤링/PDF 파싱 후 마크다운 파일로 저장
-------	--------------------------

- 데이터 출처

국가	출처	형식	규모	출처 URL	활용 용도
US	Wattpad P	HTML	2건	콘텐츠 가이드라인 , 장르 분류	번역 결과의 민감표현 감지 기준 / 국가별 권장 분량 산정 근거 / 현지화 가이드의 플랫폼 규정 항목
	Tapas P	HTML	1건	콘텐츠 가이드라인	
	WebNovel P	HTML	2건	콘텐츠 가이드라인 , 작가 정책	
JP	小説家になろう	HTML	1건	가이드라인	
	カクヨム	HTML	1건	공식 가이드라인	
	アルファポリス	HTML	1건	게시 가이드라인	
CN	起点中文网 (Qidian)	HTML	1건	콘텐츠 기준	중국 현지화 가이드의 규제 준수 기준
	番茄小说 (fanqie novel)	HTML	1건	콘텐츠 검열	
	晋江文学城 (진강문학성)	HTML	1건	플랫폼가이드라인	
	국가신문출판국 (国家新闻出版署)	PDF + HTML	2건 PDF 281KB	온라인 문학 출판 관리 규정 , 네트워크 출판 서비스 관리 규정	
TH	Computer Crime Act (2017), MDES 규정	PDF	1건 418KB	영문번역본	태국 현지화 가이드의 법적 제약 근거
	ReadAWrite	HTML	1건	FAQ	번역 결과의 민감표현
	Dek-D	HTML	1건	콘텐츠 등급	감지 기준 / 국가별 권장 분량 산정 근거 / 현지화

국가	출처	형식	규모	출처 URL	활용 용도
	Joylada	HTML	1건	콘텐츠 게시 규칙	가이드의 플랫폼 규정 항목

3-2. 국가별 문화 코드·심의 규정 (4개국)

KOCCA의 국가별 문화·소비 특성 자료는 **US, JP, CN, TH** 네 국가의 문화 코드와 독자 특성을 비교하는 데 활용한다. 각 파일은 **국가별 문화 맥락, 소비 특성, 소통 방식 차이**를 설명하는 기준 자료로 사용한다.

- 데이터 예시

수집 데이터 요약	PDF (총 12건)
수집 데이터 예시	태국의 문화 코드 국왕과 왕실에 대한 존중 - 태국의 정식 국명은 '타이 왕국(Kingdom of Thailand)'이며, '타이(Thai)'라는 단어는 '자유'라는 의미를 지님. 태국은 국왕이 국가의 원수인 입헌군주제를 채택하고 있으며, 국왕의 위엄과 권력은 절대적인 것으로 간주됨 - 태국은 국왕을 포함한 왕실 구성원을 모독하거나 왕가를 부정적으로 묘사하는 경우 처벌을 할 수 있는 법률이 있으며, 외국인도 왕실모독죄로 처벌을 받을 수 있음. 이로 인해 국왕 또는 왕실의 사진이나 그림을 손가락으로 가리키는 등 모욕적인 행동을 하지 않도록 주의해야 함 - 국왕과 왕비의 사진은 태국 곳곳에 걸려 있으며, 국왕의 사진을 걸어 놓은 집도 많음. 국왕의 사진이 있는 지폐를 고의로 찢는 경우에도 처벌을 받을 수 있음 - 태국 극장에서는 영화 상영 전에 국왕찬가가 나오며, 이는 왕에 대한 존경심을 표현하기 위한 것. 사람들은 노래가 끝날 때까지 일어서서 노래를 함께 부르기도 함 - 출처: 한국콘텐츠진흥원 - 태국의 문화 코드
수집 방법	PDF 파싱 후 마크다운 파일로 저장

- 데이터 출처

국가	출처	형식	규모	출처 URL	활용 용도
복합	한국콘텐츠진흥원 (KOCCA)	PDF	12건 (4개국 * 3종) 총 용량: 7.64MB US - 10p/1,802.6KB JP - 13p/1,899KB CN - 12p/1,864KB TH - 14p/2,257.9KB	국가별 문화코드	문화권 오해 유발 표현 감지 및 국가별 독자 특성 + 현지화 가이드

3-3. 현지화 표현 사전·코퍼스

US는 IdiomKB와 영어 관용구·구동사 관련 사전을 활용한다. 이 자료는 영어권 관용구, 구동사, 문맥 의존 표현의 한국어 현지화 매핑 기준을 제공한다. JP는 JMdict 계열 데이터와 일본어 고유명사·일반어휘 매핑 자료를 활용한다.

CN은 성어를 쉬운 표현으로 풀어쓴 병렬 데이터와 성어 문맥 판별 데이터셋을 활용한다. 이 자료는 직역이 부자연스러운 표현을 문맥 기반으로 의역하는 데 사용한다. TH는 PyThaiNLP 기반의 단어·고유명사·성씨 사전을 활용하고, KR은 Kiwi와 한국어 혐오표현 데이터셋을 활용해 원문에서 고유명사 및 민감 표현을 식별하는 기준으로 사용한다.

- 데이터 예시 (JSON)

수집 데이터 요약	JSON (총 249,826건)
수집 데이터 예시	<pre>{ "id": 1, "idiom": "1 o'clock \\"sharp\\"", "en_meaning": "punctually at 1 o'clock; being exactly on time", "zh_meaning": "1点整", "ja_meaning": "厳密に1時に" }</pre> - 출처: IdiomKB

수집 방법	JSON 파일 저장
-------	------------

- 데이터 구성 항목

항목명	설명	예시
id	식별 아이디	1
idiom	관용구	1 o'clock \ "sharp\"
en_meaning	idiom의 영어 번역	punctually at 1 o'clock; being exactly on time
zh_meaning	idiom의 중국어 번역	1点整
ja_meaning	idiom의 일본어 번역	厳密に1時に

- 데이터 예시 (CSV)

수집 데이터 요약	CSV (총 115,529건)	
수집 데이터 예시		
	src	dst
	据称，许多这些案件是由当地有钱有势人家、包括法官和政客的子弟干的，所以敢色胆包天、逍遥法外。	据称，许多这些案件是由当地有钱财和势力的人家、包括法官和政客的子弟干的，所以敢于犯法，不受法律的管制。
	- 출처: CIP	
수집 방법	CSV 파일 저장	

- 데이터 구성 항목

항목명	설명	예시
src	중국어 성어	据称，许多这些案件是由当地有钱有势人家、包括法官和

		政客の子弟干的，所以敢色胆包天、逍遥法外。
dst	중국어 해설	据称，许多这些案件是由当地有钱财和势力的人家、包括法官和政客的子弟干的，所以敢于犯法，不受法律的管制。

- 데이터 출처

국가	출처	형식	규모	출처 URL	활용 용도
US	IdiomKB -EN/CN/JP 관용구 Englishidioms	JSON	12,903건 (EN 3,990건, CN 8,643건, JP 270건) 3.85MB 22,209건 약 26MB	IdiomKB Github_englishidioms	다국어 관용구 의미 매핑 영어권 관용구/구동사 현지화 매핑
JP	jmdict-simplified kotowaza	JSON	214,644건 114MB 70건 91.4KB	Github_jmdict-simplified Github_kotowaza	일본어 고유명사·일반어휘 매핑 기준
CN	CIP	CSV	115,529건 54MB	Github_Chinese-Idiom-Paraphrasing	의역생성, 관용구 설명, 문장 단순화에 활용(성어 직역하지 않고 뜻 기반으로 현지화 번역)

국가	출처	형식	규모	출처 URL	활용 용도
TH	pythainlp	HuggingFace Dataset	62,101건	PyThaiNLP	고유명사·성씨 식별 및 토큰나이징, 감성분석

4. 데이터 수집 파이프라인

수집 대상은 PDF, HTML, CSV, JSON, 외부 데이터셋 등 다양한 형식으로 구성되므로, 형식별 수집 경로를 분리한다. 전체 흐름은 출처 식별, 수집 가능성 검증, 형식별 수집, 원시 저장, 수집 검증의 순서로 운영한다.

4-1. 수집 파이프라인 흐름

[1. 출처 식별] → [2. 수집 가능성 검증] → [3. 형식별 수집] → [4. 저장] → [5. 수집 확인]

- (1) [출처 식별]: 출처 목록에서 대상 URL·데이터셋 확정, 형식 분류 ((PDF/HTML/JSON/CSV/HF)
- (2) [수집 가능성 검증]: robots.txt 확인, 이용 약관·라이선스 검토, 저작권 제한 여부 확인
- (3) [형식별 수집]: HTML은 요청 후 본문을 파싱, PDF는 다운로드 후 텍스트 추출,
- (4) 저장: HTML, PDF 파일 외 JSON, CSV 파일은 가공/변환 없이 원본 형태로 data/raw/에 보존 (재현성 확보)
- (5) 수집 검증: 수집 건수, URL 접근성, 형식 일치 여부, 누락 여부를 확인

4-2. 수집 검증 체크 리스트

출처 신뢰성은 공식 문서, 플랫폼 공식 가이드, 공공기관 자료를 기준으로 확인한다. 법적 이용 가능성은 라이선스, 이용약관, 크롤링 허용 여부, 저작권 침해 가능성으로 판단한다. 개인정보 및 보안은 민감정보 포함 여부를 확인하며, 최신성은 정책·규제·트렌드 반영 여부로 검토한다.

검증 항목	검토 내용
-------	-------

출처 신뢰성	공식 문서, 플랫폼 공식 가이드, 공공기관 자료, URL 접근 가능 여부
법적 이용 가능성	라이선스·이용약관·크롤링 허용·저작권 침해 가능성
개인정보 및 보안	민감·개인정보 포함 여부
최신성	정책·규제·트렌드 반영 여부
획득 완전성	수집 건수, 누락·접근 실패 여부