

인공지능 데이터 전처리 결과서

프로젝트명: AI 기반 웹소설 글로벌 현지화 동시 연재 어시스턴트 – 라이터(w.LIGHTER)

팀명: 이세계출판부 (SKN24-5Team)

팀원: 고아라, 김유진, 권민제, 이동민, 진세형, 최현진

문서 버전: v1.0

작성일: 2026-05-28

목차

1. 관용표현 데이터 전처리
 - 1.1. 개요 및 원천 데이터
 - 1.2. 전처리 과정
 - 1.3. 전처리 전후 예시
 - 1.4. 결과 요약 및 활용 방안
2. 관용표현 데이터 전처리
 - 2.1. 수집 및 전처리 과정
 - 2.2. 국가별 검수 제약 규칙
 - 2.3. 현황 및 향후 보완 사항

1.관용표현 데이터 전처리

1.1 개요 및 원천 데이터

본 문서는 웹소설 현지화 번역 및 검수에 활용할 국가별 관용표현 데이터를 RAG 참조 데이터로 구축하기 위해 수행한 전처리 과정을 정리한 결과서이다. 한국어 관용어 기준셋을 기준 anchor로 사용하여 중국어, 태국어, 영어권, 일본어 관용표현 데이터를 연결하고 공통 JSON 구조로 변환하였다.

국가/언어	원천 데이터	원천 규모	활용 목적
한국어	한국어 관용어 기준셋	430건	국가별 표현 매핑 기준 anchor
중국어	Chinese-Idiom-Paraphrasing	95,560건	중국어 성어 포함 문장 및 의미 보존 paraphrase 후보
중국어	IdiomKB zh_idiom_meaning	8,643건	중국어 성어 의미 보조 데이터
태국어	PyThaiNLP 및 태국어 관용표현 후보	원천별 상이	태국어 처리 및 관용표현 후보 구축
영어	englishidioms	21,866건	영어 관용구·구동사·표현 후보
영어	IdiomKB en_idiom_meaning	3,990건	영어 관용표현 의미 보조 데이터
일본어	jmdict-simplified	217,076건	일본어 단어·표현 후보
일본어	일본어 속담·관용구 후보	70건	일본어 관용표현 후보 보강

국가별 원천 데이터는 출처와 형식이 서로 달라 전처리 없이 활용하기 어려웠다. 중국어·영어권 데이터의 표현 범위 과다, 일본어 데이터의 원천 규모 과다, 태국어 데이터의 예문 누락이 주요 진단 결과로 확인되었으며, 국가별 특성에 맞춰 후보 선별, 필드 보강, 예문 필드 정규화를 수행하였다.

점검 항목	확인 내용	처리 방향
파일 형식	JSON, CSV, JSONL 등 원천 파일 형식 확인	공통 JSON 구조로 변환

필드 결측	표현, 의미, 예문, 한국어 대응 표현 누락 여부 확인	필수값 누락 시 제외 또는 보강
언어 혼입	expression 필드에 대상 언어가 아닌 값이 들어갔는지 확인	국가별 언어 기준에 맞지 않는 항목 제외
예문 누락	예문이 없는 항목 존재 여부 확인	예문이 없으면 빈 배열로 통일
이상 데이터	관용표현이 아닌 일반 단어, 활용성이 낮은 표현 확인	웹소설 현지화 활용성 기준으로 제외
중복·유사 표현	의미가 과도하게 중복되는 항목 확인	최종 선별 시 우선순위 조정

1.2 전처리 과정

전처리는 원천 데이터를 RAG 검색과 번역 프롬프트에 활용 가능한 참조 데이터로 재구성하는 것을 목표로 수행하였다. 공통 JSON 스키마 정의, 결측치 처리, 대상 언어 검증, 이상 데이터 제거, LLM 기반 의미·맥락 보강, 한국어 anchor 매핑 순서로 진행하였다.

공통 JSON 스키마 정의

국가별 원천 데이터의 파일 형식과 필드 구성이 서로 달라, 검색·필터링·프롬프트 삽입에 공통으로 사용할 JSON 스키마를 먼저 정의하였다. 이를 통해 국가별 데이터가 동일한 방식으로 처리될 수 있도록 하였다.

필드	설명
id	국가별 표현 데이터 식별자
country / language	대상 국가 코드 및 언어 코드
expression	원어 관용표현
meaning	한국어 기반 의미 설명
original_meaning	원천 데이터의 원문 의미 또는 기존 의미 설명
ko_expression	한국어 대응 표현 후보
usage	웹소설 번역에서 활용 가능한 상황
scene / tone	활용 가능한 장면 태그와 표현 분위기

caution	직역 또는 과사용 시 주의사항
examples / examples_original	예문 또는 원문 예문

결측치 및 빈 값 처리

expression 또는 meaning이 비어 있는 항목은 제외하였다. 예문은 필수 요건으로 두지 않았으며, 원천 데이터에 예문이 있으면 유지하고 없으면 필드를 삭제하였다.

대상 언어 검증

각 국가별 expression 필드가 대상 언어 표현으로 구성되어 있는지 확인하고, 표현 후보가 불명확한 항목은 제외하였다.

이상 데이터 및 저활용 표현 제거

일반 단어, 의미가 지나치게 추상적인 항목, 웹소설 번역 장면에서 활용성이 낮은 항목을 제외하였다. RAG 검색 결과의 품질 유지를 위한 조치이다.

제외 기준	설명
표현 원문이 불명확한 항목	실제 번역 후보로 사용하기 어려움
의미 설명이 부족한 항목	검색 근거로 활용하기 어려움
일반 단어에 가까운 항목	관용표현 현지화 데이터로 보기 어려움
한국어 anchor와 연결성이 낮은 항목	한국어 원문 기반 검색에 부적합
웹소설 장면 활용성이 낮은 항목	번역 프롬프트 참조 데이터로 활용 어려움

LLM 기반 의미·맥락 보강

원천 데이터만으로는 웹소설 현지화 참조 데이터로 활용하기 부족한 항목이 많았다. 일부 데이터는 표현과 기본 의미만 제공되었고, 번역 과정에서 필요한 사용 맥락, 장면, 톤, 주의사항이 부족하였다. 이에 따라

GPT-5.4-mini를 활용하여 의미 설명, 한국어 대응 표현, 사용 맥락, 장면 태그, 톤, 주의사항을 보강하였다. 보강 목적은 단순 번역이 아니라, 번역 프롬프트에서 참고할 수 있는 설명형 데이터를 구축하는 데 두었다.

한국어 anchor 매핑

본 프로젝트는 한국어 웹소설 원문을 기준으로 번역과 검수가 이루어지기 때문에, 국가별 관용표현을 단순히 국가별 목록으로 저장하는 것만으로는 활용성이 낮다. 따라서 한국어 관용어 기준셋을 기준 anchor로 사용하여, 국가별 표현이 어떤 한국어 관용표현과 의미적으로 연결되는지 매핑하였다.

추가 필드	설명
ko_anchor_expression	한국어 관용어 기준셋 중 의미적으로 연결되는 표현
translation_strategy	관용구 치환, 의미풀이, 의미 대응 등 번역 전략
fit_score	한국어 anchor와 국가별 표현 간 의미 적합도

1.3 전처리 전후 예시

아래는 원천 데이터가 공통 JSON 구조로 변환되는 과정을 보여주는 예시이다.

전처리 전

```
{
  "id": 2,
  "idiom": "Bob's your uncle",
  "en_meaning": "used to mean that something will be successful or easy to achieve",
  "zh_meaning": "完事了",
  "ja_meaning": "簡単な手順で問題が解決する"
},
```

전처리 후

```
{  
  
  "id": "US_000002",  
  
  "country": "US",  
  
  "language": "en",  
  
  "expression": "Bob's your uncle",  
  
  "meaning": "어렵지 않게 끝난다, 그렇게 하면 된다.",  
  
  "original_meaning": "used to mean that something will be successful or easy to achieve",  
  
  "ko_expression": [  
  
    "이렇게 하면 끝",  
  
    "그거면 됐지",  
  
    "식은 죽 먹기"  
  
  ],  
  
  "usage": "가벼운 대사나 설명에서 어떤 절차가 손쉽게 마무리되거나 해결될 때 참고할 수 있다.",  
  
  "scene": [  
  
    "대사",  
  
    "해결",  
  
    "설명",  
  
    "가벼운 분위기"  
  
  ],  
  
  "tone": [  
  
    "구어체",  
  
    "유쾌함",  
  
    "비격식"  
  
  ],  
  
  "caution": "직역하면 어색하므로 한국어의 자연스러운 관용으로 바뀌어야 한다. 너무 과장된 속어는 피하고 문맥상 가벼운 뉘앙스를 맞춘다.",  
  
  "examples": [  
  
    "Splendid. Okay. Bob's your uncle. Right. Let's have a look at it."
```

```
],  
  "ko_anchor_expression": [  
    "식은 죽 먹기"  
  ],  
  "translation_strategy": "idiom",  
}
```

1.4 결과 요약 및 활용 방안

전처리 결과는 보강 후 데이터와 최종 anchor 매핑 데이터로 구분하여 관리하였다. 실제 RAG 활용 파일은 anchor 매핑이 완료된 *_ko_anchored.json 파일이며, 최종 활용 파일은 다음과 같다.

국가/언어	보강 후 데이터	최종 데이터	비고
한국어	430건	430건	국가별 매핑 기준 anchor
중국어	3,132건	548건	한국어 anchor 약 202종 커버
태국어	1,152건	175건	한국어 anchor 약 120종 커버
영어권	1,936건	360건	한국어 anchor 약 172종 커버
일본어	300건	300건	한국어 기준 표현 기반 최종 후보, 전체 예문 포함

파일명	설명
ko_idiom_shortlist.json	한국어 관용어 기준셋
cn_idiom_references_ko_anchored.json	중국어 최종 현지화 관용표현 데이터
th_idiom_references_ko_anchored.json	태국어 최종 현지화 관용표현 데이터
us_idiom_references_ko_anchored.json	영어권 최종 현지화 관용표현 데이터
jp_idiom_references_ko_anchored.json	일본어 최종 현지화 관용표현 데이터

최종 데이터는 한국어 원문에서 관용표현이 등장했을 때 대상 국가의 표현 후보 검색 또는 번역 프롬프트 참조 정보로 활용한다. 향후에는 번역 결과와 사용자 피드백을 기반으로 표현을 보완하고, 문화적 배경 치환 데이터와 플랫폼별 콘텐츠 가이드라인 데이터를 추가하여 검수 범위를 확장할 계획이다.

2. 관용표현 데이터 전처리

관용표현 RAG 데이터와는 별도로, 검수 에이전트가 국가별 민감 표현을 판단하는 데 쓸 제약 규칙 데이터를 수집·정리했다. 대상 국가는 태국(TH), 일본(JP), 미국(US), 중국 본토(CN)이며, 번역 후보 검색이 아닌 검수 판단 기준으로 활용한다.

2.1 수집 및 전처리 과정

각국 법령, 정부 공식 가이드, 관광청 자료를 웹 크롤링으로 수집하고 근거 유형(Direct law / Official policy / Official etiquette / Localization inference)에 따라 분류했다. 규칙 추출과 파일 구조화에는 LLM을 활용했으며, 직접 법령 근거가 없는 항목은 Localization inference로 명시해 관리한다.

수집 데이터 요약

PDF (총 12건) — welcon.kocca.kr/mobile/ko/biz-culture/

국가	출처	형식	규모	출처 URL	활용 용도
TH	한국콘텐츠진흥원 (KOCCA)	PDF	3건, 14p 2,257.9KB	biz-culture /49·/23·/22	문화코드·심의규정 기반 검수 제약 규칙 구성
JP	“	PDF	3건, 13p 1,899KB	biz-culture /34·/11·/10	“
US	“	PDF	3건, 10p 1,802.6KB	biz-culture /35·/5·/4	“
CN	“	PDF	3건, 12p 1,864KB	biz-culture /33·/8·/7	“

수집 방법

KOCCA PDF 다운로드 후 마크다운 파일로 저장

검수 에이전트는 공통 기반 프롬프트에 해당 국가 파일을 합쳐 동작한다. 파일을 국가별로 분리한 이유는 관계없는 규칙이 섞이면 오탐이 늘고 프롬프트가 불필요하게 길어지기 때문이다.

2.2 국가별 검수 제약 규칙

4개국 각각에 대해 국가별 제약 파일이 구성되어 있으며, 각 파일은 해당 국가 전용 규칙만 포함한다. 아래는 일본(JP) 제약 규칙을 예시로 든다.

ID	Category	Severity	Action	Trigger (KO)
JP01	HISTORY_WAR	CRITICAL	FLAG	식민지배, 위안부, 난징, 전범, 군국주의, 야스쿠니
JP02	ATROCITY_JOKE	CRITICAL	BLOCK	전쟁범죄, 식민, 학살, 원폭 피해를 농담/밈으로 사용
JP04	DISASTER_JOKE	CRITICAL	BLOCK	지진/쓰나미/원폭 피해 희화화, 과장 개그
JP05	IMPERIAL_FAMILY	HIGH	FLAG	천황, 황실, 일왕, 황족 + 조롱/희화화/비하
JP08	HONORIFIC_BREAKDOWN	HIGH	ADAPT	연장자/상사/낯선 상대에게 반말, 막말, 지나친 직설
JP09	ADDRESS_TERM_RISK	MEDIUM	ADAPT	너, 당신, 이름만 호출, 호칭 생략, -상/-씨 대응 실패
JP10	PUBLIC_BEHAVIOR	MEDIUM	NOTE	대중교통 큰소리, 공개 언쟁, 소란, 통화, 줄서기 무시

JP14	ONSEN_ETIQUETTE	MEDIUM	NOTE	온천 입욕 전 안 씻기, 수건 담그기, 머리카락 물에 닿기
------	-----------------	--------	------	-------------------------------------

처리 방식은 근거 유형(Direct law / Official policy / Localization inference)과 리스크 성격(법적 리스크 vs 현지화 품질)에 따라 결정한다. 법령·공식 가이드 기반 항목은 FLAG 또는 BLOCK, 현지화 품질·독자 경험 관련 항목은 ADAPT 또는 NOTE로 처리한다.

각 처리 방식의 기준은 다음과 같다.

BLOCK: 심각한 집단 트라우마(학살, 재난, 식민지배 등)를 능동적으로 희화화·조롱하는 경우. 단순 언급이나 중립적 서술은 해당하지 않음.

FLAG: 민감 주제가 포함되나 맥락에 따라 허용될 수 있어 검토가 필요한 경우. Direct law 또는 Official policy 근거 규칙이 주로 해당.

ADAPT: 번역 품질 문제(경어·어조·호칭 등)로 내용 차단 없이 표현 조정이 필요한 경우.

NOTE: 장면 리얼리티나 예절 문제로 독자 몰입을 저해할 수 있으나 직접적 리스크는 낮은 경우.

2.3 현황 및 향후 보강 계획

제약 데이터는 KOCCA 해외진출기초정보, 각국 법령, 공식 관광·에티켓 가이드를 기반으로 구성했다. 태국은 왕실모독죄(형법 §112)와 NBTC 방송법 등 직접 법령이 명확하고, 미국은 EEOC·U.S. DOJ 기반 근거가 비교적 잘 정리되어 있다. 중국은 콘텐츠 검열 규제 자체가 자세하여 핵심 항목 대부분이 직접 법령이나 공식 가이드로 커버된다. 일본은 KOCCA와 JNTO 자료를 주로 활용했으며, 소수자·비유 관련 항목 일부는 추가 보강이 남아 있다. 출처가 부족한 항목은 실운용 중 오탐 여부를 확인하며 점진적으로 보완할 예정이다.