

수집된 데이터 및 데이터 전처리 문서

프로젝트명: AI 기반 웹소설 글로벌 현지화 동시 연재 어시스턴트 – 라이터(w.LIGHTER)

팀명: 이세계출판부 (SKN24-5Team)

팀원: 고아라, 김유진, 권민제, 이동민, 진세형, 최현진

문서 버전: v1.0

작성일: 2026-05-28

목차

1. 문서 개요
2. 수집 데이터 개요
3. 실제 파일 흐름
4. 실제 전처리 파이프라인 상세
5. 전처리 과정에서 확인된 이슈와 처리 방식
6. 최종 산출 파일 목록
7. 향후 보완 사항

1. 문서 개요

본 문서는 w.LiGHTER 서비스의 현지화 번역·검수 기능을 위해 수집한 데이터와 실제 전처리 과정을 정리한 문서이다. 원본 데이터는 국가별로 제공 형식과 품질이 달랐기 때문에, 먼저 파일 구조를 확인한 뒤 필요한 필드만 추출하고, 이후 공통 JSON 구조로 맞추는 방식으로 작업하였다. 이 과정에서 단순히 데이터를 줄이는 것보다 웹소설 번역에 실제로 참고할 수 있는 표현인지, 대사나 서술에 넣었을 때 어색하지 않은지, 국가별 문화 맥락을 설명할 수 있는지를 우선적으로 보았다.

2. 수집 데이터 개요

국가/구분	수집 파일 또는 출처	규모	수집 목적
대한민국/한국어	ko_idiom_shortlist.json	430건	한국어 관용표현과 aliases를 기준으로 국가별 표현을 연결
미국/영어권	english.json	21,866건	영어 관용구 원천 후보
미국/영어권	en_idiom_meaning.json	3,990건	영어 관용구 의미 보조 데이터
미국/영어권	MAGPIE_filtered_split_random.jsonl	48,395문장	영어 관용구 실제 사용 예문 및 빈도 참고
중국	zh_idiom_meaning.json	8,643건	중국어 성어 의미 데이터
중국	zh_train.csv	95,560행	성어 포함 문장과 paraphrase 문장
일본	kotowaza.json	70건	일본어 속담·격언 후보
일본	ja_idiom_meaning.json	270건	일본어 표현 의미 보조 데이터
태국	Hugging Face pythainlp/thai-idioms-instruction	정규화 1,152건	태국어 관용표현 instruction 데이터

3. 실제 파일 흐름

국가	원천 데이터	중간 산출 파일	최종/보강 파일
미국	english.json / en_idiom_meaning / MAGPIE	us_idiom_references_all.json → us_idiom_references_all_internal. json	us_idiom_references_enriched.json
중국	zh_idiom_meaning / zh_train.csv	cn_idiom_references_all.json → cn_idiom_references_with_exam ples.json → cn_idiom_references_selected.jso n	cn_idiom_references_enriched.json
일본	kotowaza / ja_idiom_meaning	일본어 표현 후보 통합 및 필드 정규화	jp_idiom_references_enriched.json
태국	pythainlp/thai-idioms-instruction	th_idiom_references.json → th_idiom_references_enriched.jso n → th_idiom_anchor_candidates.json	th_idiom_references_ko_anchored.json

4. 실제 전처리 파이프라인 상세

- 원본 파일을 JSON, CSV, JSONL 형식에 맞춰 로드하고 파일별 최상위 구조를 확인하였다.
- 표현 필드는 expression, 의미 필드는 original_meaning으로 우선 정규화하였다.
- country, language, id를 국가별 규칙에 맞게 부여하였다.
- 예문이 없는 데이터는 examples_original을 빈 배열로 두어 후속 처리에서 오류가 나지 않도록 통일하였다.

- LLM 보강 전에는 meaning, ko_expression, usage, scene, tone, caution 필드를 비워 두고, 보강 후 채우는 방식으로 관리하였다.

4.2 미국 데이터 처리

미국 데이터는 원천 후보가 많았기 때문에 english.json의 사전형 관용구와 en_idiom_meaning의 의미 데이터를 먼저 정규화하였다. 이후 MAGPIE의 실제 문장 사용 예시를 expression 기준으로 연결하여, 단순 사전 표현이 아니라 실제 문맥에서 쓰인 흔적이 있는 표현을 우선적으로 남겼다.

항목	내용
원본 후보	english.json 21,866건, en_idiom_meaning 3,990건
실사용 예문	MAGPIE 48,395문장. idiom, context, genre, confidence, variant_type 참고
중간 산출	us_idiom_references_all 3,783건
보강 산출	us_idiom_references_enriched 1,936건
특징	구어체·비격식 표현이 많아 tone과 caution 필드 보강 비중이 큼

미국 데이터 샘플 - 전처리 전

```
{
  "id": "US_000002",
  "country": "US",
  "language": "en",
  "expression": "Bob's your uncle",
  "meaning": null,
  "original_meaning": "used to mean that something will be successful or easy to achieve",
  "examples_original": [
    "Splendid . Okay . Bob 's your uncle . Right . Let 's have a look at it ."
  ]
}
```

미국 데이터 샘플 - 전처리 후

```
{
  "id": "US_000002",
  "country": "US",
  "language": "en",
  "expression": "Bob's your uncle",
  "meaning": "어렵지 않게 끝난다, 그렇게 하면 된다.",
  "original_meaning": "used to mean that something will be successful or easy to achieve",
  "ko_expression": [
    "이렇게 하면 끝",
    "그거면 됐지",
    "식은 죽 먹기"
  ],
  "usage": "가벼운 대사나 설명에서 어떤 절차가 손쉽게 마무리되거나 해결될 때 참고할 수 있다.",
  "scene": [
    "대사",
    "해결",
    "설명",
    "가벼운 분위기"
  ],
  "tone": [
    "구어체",
    "유쾌함",
    "비격식"
  ],
  "caution": "직역하면 어색하므로 한국어의 자연스러운 관용으로 바꿔야 한다. 너무 과장된 속어는 피하고 문맥상 가벼운 뉘앙스를 맞춘다.",
  "examples": [
    "Splendid. Okay. Bob's your uncle. Right. Let's have a look at it."
  ],
  "ko_anchor_expression": [
    "식은 죽 먹기"
  ],
  "translation_strategy": "idiom",
}
```

4.3 중국 데이터 처리

중국 데이터는 성어 수가 많고 예문 데이터가 별도로 존재했기 때문에, 먼저 zh_idiom_meaning의 성어 목록을 기준으로 정규화한 뒤 zh_train.csv의 src/dst 문장에서 해당 성어가 등장하는 예문을 찾아 연결하였다. 이후 빈도와 예문 품질을 기준으로 선별하여 LLM 보강 대상을 줄였다.

항목	내용
성어 의미 원천	zh_idiom_meaning 8,643건 → 유효 8,639건
문장 원천	zh_train.csv 95,560행 중 88,781행 매칭
예문 포함	6,193건
최종 선별	점수 기준으로 3,132건 선정
스키마 검증	invalid_count 0건
보강 산출	cn_idiom_references_enriched 3,132건

중국 데이터 샘플 - 예문 포함 전처리 데이터

```
{
  "id": "CN_000002",
  "country": "CN",
  "language": "zh",
  "expression": "一败涂地",
  "meaning": null,
  "original_meaning": "比喻遭到彻底失败，一片狼藉",
  "examples_original": [
    "分散投资是一败涂地，因为各个股票市场几乎都已唇齿相依、休戚相关。"
  ]
}
```

중국 데이터 샘플 - 보강 후

```
{
  "id": "CN_003585",
  "country": "CN",
  "language": "zh",
  "expression": "视而不见",
  "meaning": "분명 보고도 못 본 척하며 모른 체함",
  "original_meaning": "形容对某事物明明看到了，但装作没看见，不予理会",
  "ko_expression": [
    "못 본 척하다",
    "모른 체하다",
    "눈감아 주지 않고 외면하다"
  ],
  "usage": "누군가의 실수나 불편한 상황을 알고도 일부러 반응하지 않는 장면, 혹은 사실을 알면서도 넘어가는 묘사에  
참고할 수 있다.",
  "scene": [
    "회사내부",
    "감정회피",
    "갈등무시",
    "불편한진실"
  ],
  "tone": [
    "무심한",
    "냉담한",
    "회피적인"
  ],
  "caution": "직역보다 '못 본 척' 뉘앙스로 살리고, 대사체에선 과한 성어 사용을 피하세요.",
  "examples": [
    "独立不是要关起门来，也不是要固步自封，对外国的每件事情都视而不见。"
  ],
  "ko_anchor_expression": [
    "눈을 감다"
  ],
  "translation_strategy": "paraphrase",
}
```

4.4 일본 데이터 처리

일본 데이터는 이전 초안에서 빠졌던 부분을 보완하였다. kotowaza 데이터는 reading, romaji, literal, tags, examples처럼 속담 학습에 유용한 필드가 많았고, ja_idiom_meaning은 보다 넓은 일본어 표현 후보를 제공했다. 최종 문서에서는 두 원천을 함께 사용해 일본어 속담·관용표현 후보를 구성한 것으로 정리하였다.

항목	내용
원천 1	kotowaza(1).json 70건 - japanese, reading, romaji, literal, meaning, examples 포함
원천 2	ja_idiom_meaning.json 270건 - idiom, en_meaning, zh_meaning, ja_meaning 포함
보강 산출	jp_idiom_references_enriched.json 219건
처리 방향	격언적 표현, 일상 관용구, 호칭·어조 차이를 설명할 수 있도록 usage, tone, caution을 보강

일본 데이터 샘플 - 원천 데이터

```
{
  "id": "nanakorobi-yaoki",
  "japanese": "七転び八起き",
  "reading": "ななころびやおき",
  "romaji": "Nanakorobi Yaoki",
  "literal": "Fall seven times, rise eight times",
  "meaning": {
    "id": "Betapapun banyaknya kegagalan yang dialami, jangan pernah menyerah dan teruslah bangkit kembali.",
    "en": "No matter how many times you fail, never give up and keep getting back up."
  },
  "tags": [
    "motivation",
    "numbers",
    "life"
  ]
}
```

일본 데이터 샘플 - 보강 후

```
{
  "id": "jp-00001",
  "country": "Japan",
  "language": "ja",
  "expression": "一石二鳥",
  "meaning": "한 번의 행동으로 두 가지 이익을 얻는 것",
  "original_meaning": "Achieving two benefits from a single action.",
  "ko_expression": [
    "일석이조",
    "두 마리 토끼를 잡다",
    "한 번에 두 가지 효과",
    "굉장 먹고 알 먹기",
    "한번에 두 가지를 얻다"
  ],
  "ko_anchor_expression": [
    "일석이조",
    "굉장 먹고 알 먹기"
  ],
  "usage": "원문이 한 행동의 결과로 이익이 2개 생긴다는 뜻일 때 참고합니다. 한국어에서는 관용구 대응 가능하지만 문체 차이는 확인하세요.",
  "scene": [
    "업무 효율",
    "절약",
    "운동과 실익",
    "문제 해결"
  ],
  "tone": [
    "일상적",
    "비유적",
    "긍정적"
  ],
  "caution": "한국어의 '일석이조'가 가장 가깝지만, 문장 톤에 따라 '두 마리 토끼를 잡다'는 더 구어적일 수 있습니다. 직역보다 관용구 치환이 자연스러운 편입니다.",
  "examples": [
    "自転車通勤すれば、運動にもなりし交通費も節約できて一石二鳥だ。"
  ],
  "translation_strategy": "idiom",
}
```

4.5 태국 데이터 처리

태국 데이터는 Hugging Face의 pythainlp/thai-idioms-instruction 데이터를 기준으로 정규화하였다. 태국어 원문이 깨지지 않도록 문서에는 UTF-8 원문을 그대로 보존했고, Word 표시 시에도 태국어 expression과 original_meaning을 삭제하거나 영문 치환하지 않았다. 예문이 없는 항목이 많았기 때문에 examples_original은 빈 배열로 유지하였다.

항목	내용
원천 출처	https://huggingface.co/datasets/pythainlp/thai-idioms-instruction
정규화 산출	th_idiom_references.json 1,152건
보강 산출	th_idiom_references_enriched(1).json 1,152건
anchor 후보	후보 205건, 후보 없음 947건
최종 anchor	th_idiom_references_ko_anchored(1).json 205건
처리 방향	무리한 매핑을 피하고, 한국어 shortlist와 직접 연결되는 표현만 anchor 후보로 분리

태국 데이터 샘플 - 전처리 전 정규화 데이터

```
{
  "id": "TH_000003",
  "country": "TH",
  "language": "th",
  "expression": "ที่เล่นที่จริง",
  "meaning": null,
  "original_meaning": "สร้างท่าเล่น ๆ หรือล้อหลอกเป็นการลงเชิง แต่เมื่อเห็นเขาเพลอ ตัว หรือไม่เขาก็เอาจริง",
  "examples_original": []
}
```

태국 데이터 샘플 - 보강 후

```
{
  "id": "TH_000007",
  "country": "TH",
  "language": "th",
  "expression": "ขำงงไม่พ้นคอ",
  "meaning": "자신의 행동으로 인해 해를 입음",
  "original_meaning": "สำ ทำอะไรแล้วผลร้ายกลับมาสู่ตัวเอง",
  "ko_expression": [
    "제 발등 찍기",
    "스스로 덫에 걸리다",
    "자충수",
    "돌아서 나쁜 결과를 겪다"
  ],
  "usage": "웹소설에서 인물이 자신의 잘못된 선택이나 행동으로 인해 부정적인 결과를 맞이하는 장면에서  
참고 가능하다.",
  "scene": [
    "반전",
    "자책",
    "갈등",
    "교훈",
    "심리묘사"
  ],
  "tone": [
    "진지한",
    "비극적",
    "자기반성적",
    "경고적"
  ],
  "caution": "대사나 서술에서 과도하게 사용하면 진부하거나 과장될 수 있으니 문맥에 맞게 적절한 강도로  
조절해야 한다.",
  "examples_original": [],
  "ko_anchor_expression": [
    "누워서 침 뱉기"
  ],
  "translation_strategy": "idiom",
}
```

5. 전처리 과정에서 확인된 이슈와 처리 방식

이슈	처리 방식
원천 형식 불일치	JSON, CSV, JSONL이 섞여 있어 로더와 필드 매핑을 파일별로 다르게 적용
예문 부족	태국·일본 일부 데이터는 예문이 부족하여 examples_original을 빈 배열로 통일하고 의미·사용 맥락을 보강
표현 범위 과다	중국·영어 데이터는 원천 후보가 많아 빈도, 예문 보유 여부, 표현 길이를 기준으로 선별
일반 단어 혼입	관용표현이라고 보기 어려운 항목은 최종 보강 또는 anchor 단계에서 제외
태국어 표시 문제	문서 생성 시 UTF-8 문자열을 그대로 삽입하고 세로 페이지에서 줄바꿈되도록 샘플 길이를 조절
정책 출처 검증	Wattpad seed는 source_access_status와 needs_manual_verification 필드를 유지하여 검증 필요 여부를 명시

6. 최종 산출 파일 목록

파일명	설명
ko_idiom_shortlist.json	한국어 관용어 기준셋, 국가별 표현 매핑의 anchor
us_idiom_references_enriched.json	미국/영어권 관용표현 보강 결과
cn_idiom_references_enriched.json	중국어 성어 보강 결과
jp_idiom_references_enriched.json	일본어 속담·관용표현 보강 결과
th_idiom_references_enriched.json	태국어 관용표현 보강 결과

7. 향후 보완 사항

- 미국·중국 데이터도 태국처럼 ko_anchor 최종 파일을 별도로 생성하면 RAG 평가 설명이 더 명확해진다.
- 일본 데이터는 현재 보강 결과에 anchor 정보가 포함되어 있으나, 별도 anchor 후보/탈락 리포트가 있으면 결과서의 설득력이 높아진다.
- 학습/검증/테스트 분할은 현재 설계 기준으로 작성했으므로, 실제 파일을 생성하면 산출 파일명과 건수를 추가한다.
- 정책 seed 데이터는 각 플랫폼 공식 문서 접근 여부를 재확인한 뒤 needs_manual_verification 값을 갱신한다.